Procesamiento de Datos

Trabajo Práctico 1: Elección del Dataset (Opciones del Estudiante)

Para el desarrollo de este Trabajo Práctico, los alumnos podrán optar por una de las siguientes dos modalidades:

- **Opción A (Por defecto):** Utilizar el dataset provisto por la cátedra: "Natural Disasters 1900-2021".
- **Opción B (Libre elección):** Proponer y utilizar un dataset alternativo de su interés (proveniente de Kaggle, portales de datos abiertos, etc.).

Requisitos Obligatorios para la Opción B (Auto-validación)

Si el alumno decide elegir su propio conjunto de datos, es responsabilidad exclusiva de los alumnos asegurarse de que el archivo cumpla estrictamente con las siguientes características técnicas necesarias para resolver las consignas. El dataset debe contener:

1. **Dimensión Temporal:** Columnas de tiempo explícitas (mínimo año y mes, o una fecha estructurada) para poder aplicar el proceso de transformación y análisis de estacionalidad requerido en la Consigna 2.
2. **Dimensión Categórica y Geográfica:** Al menos una variable de ubicación (países, regiones, ciudades, sucursales) y variables de categorías claras para poder realizar los 5 cruces relevantes solicitados en la Consigna 3.
3. **Necesidad de Curación:** Datos que requieran limpieza evidente (valores nulos, strings mal formateados, registros desprolijos o categorías duplicadas por errores de tipeo).
4. **Formato y Volumen:** Archivos en formato plano (.csv, .json, o .xlsx) con un volumen manejable por Pandas (se sugiere un rango de entre 2.000 y 100.000 filas).
5. **Condición de Entrega:** No se realizarán excepciones en los criterios de evaluación. Si el dataset elegido de forma libre no permite cumplir con el encapsulado del flujo o los análisis solicitados en las consignas 2 y 3, el trabajo se considerará incompleto.

Trabajo Práctico 1 - Proceso de Ingeniería de Datos con Dataset Seleccionado

Objetivo del Trabajo Práctico

Realizar un análisis exploratorio integral (EDA) mediante un proceso de datos estructurado que permita identificar patrones temporales y geográficos/categóricos en la ocurrencia de los eventos del dataset a lo largo de su registro histórico.

Consignas Detalladas

1. Extracción e Ingesta de Datos

- Implementar un módulo de extracción que utilice Pandas para leer el dataset correspondiente (el provisto "Natural Disasters 1900-2021" o el elegido por el grupo).
- Validar la correcta carga de los datos y realizar una exploración inicial de la estructura del dataset.

2. Transformación Temporal

- Unificar las columnas de tiempo (ej. año y mes) en una única columna "fecha" con formato datetime64 (o adaptar la marca de tiempo nativa del dataset a este formato estructurado).
- Generar un reporte analítico que identifique patrones estacionales en la ocurrencia de los eventos analizados.
- Focalizar el análisis en las últimas dos décadas (o el período reciente más representativo) para identificar tendencias recientes.
- Visualizar los resultados mediante gráficos temporales (series de tiempo, heatmaps estacionales).

3. Curación y Análisis de Variables

- Depurar las columnas principales de categorías y ubicación (equivalentes a "Tipo de Desastre" y "País/Región" del dataset base) mediante técnicas de imputación y estandarización.
- Analizar relaciones significativas entre los tipos de eventos principales y su ubicación geográfica o espacial.
- Seleccionar hasta 5 cruces relevantes.
    - *Ejemplos de referencia para el dataset base:* Distribución geográfica de terremotos, regiones con mayor incidencia de inundaciones, patrones regionales de sequías extremas, frecuencia de tormentas por continente, o tendencia histórica de incendios forestales por región.
    - *Para la Opción B:* El alumno deberá plantear 5 cruces de variables equivalentes y críticos que tengan sentido analítico para su temática elegida.

Estructura del Proyecto y Arquitectura

El proyecto se organizará en un directorio principal (nombrado según la temática elegida). Se admitirán dos enfoques para la estructuración y el flujo de los datos:

Enfoque 1: Arquitectura Tradicional ETL (Módulos Funcionales)

Consiste en dividir el código en tres módulos Python especializados según la fase del proceso:

- **extract/**: Módulo de extracción y lectura de datos.
- **transform/**: Módulo de transformación, curación y análisis.
- **load/**: Módulo de carga, persistencia y generación de visualizaciones.

Enfoque 2: Arquitectura Medallion (Opcional)

Si el estudiante lo prefiere, se permite estructurar el flujo del proyecto siguiendo el patrón de diseño Medallion, organizando el código y el almacenamiento en capas de madurez:

- **Capa Bronze (Raw):** Almacenamiento e ingesta de los datos en su estado crudo y validación de carga inicial.
- **Capa Silver (Cleansed/Enriched):** Procesos de curación, depuración de nulos, estandarización y transformaciones temporales/categóricas.
- **Capa Gold (Curated/Business):** Generación de los modelos agregados, cálculo de los 5 cruces de variables y preparación de los datos finales para el reporte visual.
- *Nota: Independientemente del enfoque elegido (ETL tradicional o Medallion), las funciones deben estar correctamente encapsuladas en archivos .py dentro de sus respectivos directorios o submódulos, asegurando un código limpio, modular y mantenible.*

***** Se recomienda ver el código propuesto de la clase 5 modularizado y el ejemplo de arquitectura medallion *****

Consideraciones Generales:

1. Para los puntos 2 y 3, no es necesario hacer un análisis estadístico profundo, pero es requisito que la información que reporten y los gráficos que se muestren estén acompañados de un texto con una apreciación crítica de lo que se observa.
2. Pueden acompañar la entrega de los notebooks que sean necesarios. Los gráficos pueden estar dentro de los notebooks para lo que es el reporte.
3. Es necesario que las funciones estén encapsuladas en módulos dentro de los directorios correspondientes.

Entregables:

a) Desarrollo en código modularizado mediante scripts (.py).
b) Desarrollo en código modularizado mediante notebook (.ipynb) para la etapa de análisis/reporte gráfico.

c) Informe detallando el proceso, justificación de la arquitectura elegida y las conclusiones analíticas.

Criterios de Evaluación

- **Calidad del código:** Modularidad, legibilidad, buenas prácticas de desarrollo y documentación.
- **Rigor analítico:** Aplicación correcta de transformaciones, curación de datos y manejo de la arquitectura elegida.
- **Capacidad de insight:** Identificación de patrones relevantes y comunicación clara de hallazgos.
- **Creatividad:** Selección inteligente de cruces de variables y visualizaciones efectivas.

Nota: *Se valorará especialmente la capacidad de generar insights accionables y la claridad en la presentación de resultados.*

Nota de Exclusividad para la Corrección (Garantía de Ejecución):

El código entregado por los alumnos debe ser completamente **autónomo y ejecutable "fuera de la caja"**. Esto significa que el docente, al momento de evaluar, no debe realizar ninguna modificación en las líneas de código, ni instalar dependencias no declaradas, ni reconfigurar rutas del sistema.

Se debe prestar especial atención a la gestión del dataset y su importación:

- **Accesibilidad de los datos:** El dataset utilizado debe estar incluido obligatoriamente dentro de la estructura del proyecto enviado (por ejemplo, en una carpeta `/data` o `/dataset`) o bien consumirse mediante una URL pública de acceso directo y libre (sin requerir credenciales personales).
- **Rutas relativas:** Está estrictamente prohibido el uso de rutas absolutas locales (ej: `C:/Usuarios/Alumno/Documentos/dataset.csv`). El script de extracción debe invocar al archivo utilizando rutas relativas, garantizando que el entorno corra correctamente en cualquier computadora con solo ejecutar el archivo principal.
- *El incumplimiento de esta pauta, o cualquier error que impida la ejecución inmediata del proceso por fallas en la localización del dataset, será motivo de penalización directa en la nota del trabajo.*